

Единый принцип и зачем нужны трансформеры

Дисциплина «Мультимодальная обработка данных»

Александр Чурсин
Руководитель группы
разработки в ГК «Норильский
никель»



Проверка связи

Если у вас нет звука:

- убедитесь, что на вашем устройстве и на колонках включён звук
- обновите страницу вебинара (или закройте страницу и заново присоединитесь к вебинару)
- откройте вебинар в другом браузере
- перезагрузите компьютер (ноутбук) и заново попытайтесь зайти

Поставьте в чат:

-  если меня видно и слышно
-  если нет

Рекомендации

→ Если смотрите с компьютера

- Используйте браузеры Google Chrome или Microsoft Edge
- Если есть проблемы с изображением или звуком, обновите страницу — **F5**

→ Если смотрите с мобильного телефона или планшета

- Перейдите с мобильного интернет-соединения на **Wi-Fi**
- Если есть проблемы с изображением или звуком, перезапустите приложение на телефоне

Правила участия

- 1 Приготовьте блокнот и ручку, чтобы записывать важные мысли и идеи
- 2 Продолжительность вебинара — 1 час 20 минут
- 3 Вы можете писать свои вопросы в чате
- 4 Запись вебинара будет доступна в личном кабинете Нетологии
- 5 Оффтоп обсуждения можно продолжить в учебном чате в ВК

Александр Чурсин

О спикере:

- TeamLead NLP в Норникеле
- Стажёр → тимлид команды из 10 за 5 лет
- Бакалавриат «Лингвистика»
- Магистр «Инженерия машинного обучения»
- Мультиагентные системы и дообучение
- Домены: мебель, туризм, медиа, металлургия



Как устроен курс

Идея курса

одна архитектура
на все виды данных
разбираем её с нуля
и доводим
до мультимодальной
системы

Занятия

16 вебинаров, 5 модулей:
фундамент, зрение, аудио,
структурированные данные,
мультимодальность
Практика на Python и PyTorch
Запись — на следующий день
Финал — капстоун-проект

Задания и оценка

ДЗ №1 — 50 баллов
(часть итогового задания)
ДЗ №2 — 50 баллов
Итоговый тест — 100 баллов
Итог: **ТК × 0,6 + ПА × 0,4**
Зачёт — от 40 из 100

Почему трансформер победил зоопарк архитектур

Одна архитектура на пять видов данных

Придумана для текста — работает для всего

Архитектуру 2017 года сделали для текста, а сегодня ею обрабатывают снимки, звук и показания датчиков. Прежние архитектуры так не умели.

Любые данные — это набор токенов

Трансформер работает с набором
токенов и не спрашивает, откуда они
взялись

План занятия

- 1 Зоопарк архитектур
- 2 Требование к механизму
- 3 Любые данные — набор токенов
- 4 Вход модели — матрица $L \times d$
- 5 Внимание: выигрыш и цена

Цели занятия

- Понять, что прежние архитектуры знали о данных заранее
- Увидеть, как текст, картинка, звук и ряд режутся на токены
- Разобрать вход модели: матрица X из L строк по d чисел
- Понять, почему рекуррентная сеть считает по очереди
- Понять, почему цена внимания растёт как площадь

Пять модулей — по видам данных

Модуль	О чём
1	Фундамент: устройство трансформера, текст
2	Зрение: изображения
3	Звук
4	Видео, временные ряды, таблицы
5	Мультимодальность: несколько видов сразу

Практика и требования

ДЗ после модуля 2

четверть оценки, защита на
восьмом вебинаре

Командный проект

больше трети оценки, в конце
курса

Google Colab, T4, 16 ГБ

модели до миллиарда
параметров — условие каждой
задачи

План занятия

- 1 Зоопарк архитектур
- 2 Требование к механизму
- 3 Любые данные — набор токенов
- 4 Вход модели — матрица $L \times d$
- 5 Внимание: выигрыш и цена

Каждому виду данных — своя сеть



Каждому виду данных — своя сеть



Каждому виду данных — своя сеть



своего вида данных каждая знала заранее — чужого не знала совсем

сменил вид данных — сменил всё

А можно ли иметь одну архитектуру?

Связка двух модальностей
проектировалась заново под каждую
пару.

План занятия

1 Зоопарк архитектур

2 Требование к механизму

3 Любые данные — набор токенов

4 Вход модели — матрица $L \times d$

5 Внимание: выигрыш и цена

Чего мы хотим от механизма

Вход любой длины

число элементов не зашито
при проектировании

Прямой доступ

любой элемент обращается к
любому, без посредников

Одинаковая цена

до соседа и до самого дальнего
— поровну


Никаких предположений

ни про время, ни про соседство
— всё выводится из данных

План занятия

- 1 Зоопарк архитектур
- 2 Требование к механизму
- 3 Любые данные — набор токенов**
- 4 Вход модели — матрица $L \times d$
- 5 Внимание: выигрыш и цена

Фотография становится цепочкой



Договорились о двух вещах:

как режем — здесь сетка 4×4 ,
шестнадцать квадратов одного размера;


в каком порядке их читаем — здесь слева
направо и сверху вниз, как строки текста.

Обе договорённости наши. У самой фотографии
ни нарезки, ни порядка нет.

снимок 224×224 пикселя: квадрат $16 \times 16 \rightarrow$ сетка $14 \times 14 = 196$ токенов, квадрат $32 \times 32 \rightarrow$ сетка $7 \times 7 = 49$ токенов

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Фотография становится цепочкой



Договорились о двух вещах:

как режим — здесь сетка 4×4 ,
шестнадцать квадратов одного размера;

в каком порядке их читаем — здесь слева
направо и сверху вниз, как строки текста.

Обе договорённости наши. У самой фотографии
ни нарезки, ни порядка нет.



выкладываем по порядку



одна цепочка из шестнадцати токенов — такая же, как слова во фразе

снимок 224×224 пикселя: квадрат $16 \times 16 \rightarrow$ сетка $14 \times 14 = 196$ токенов, квадрат $32 \times 32 \rightarrow$ сетка $7 \times 7 = 49$ токенов

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука


Звук режут окнами по времени



- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Звук режут окнами по времени

запись — непрерывное колебание, границы окон расставили мы



это окно



цепочка окон — столько же токенов, сколько окон мы нарезали


длина окна — наша договорённость: короче окна — больше токенов

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

У токена видео есть толщина

у токена появляется толщина по времени

соседние кадры почти одинаковы, и вся информация о движении лежит в их разнице
кадр 1 кадр 2 кадр 3




это один токен: тот же квадрат, взятый за три кадра

время

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Токен ряда — отрезок, а не точка

показания датчика: смысл появляется в форме участка, а не в одном числе



токеном берут непрерывный отрезок ряда — длину отрезка выбираем мы

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Токен таблицы — один признак

таблица: строка — запись, колонка — признак

возраст	город	сумма покупки	стаж
28	Пермь	900	1 год
34	Казань	2 400	3 года
51	Омск	5 100	7 лет

одна запись

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Токен таблицы — один признак

таблица: строка — запись, колонка — признак

возраст	город	сумма покупки	стаж
28	Пермь	900	1 год
34	Казань	2 400	3 года
51	Омск	5 100	7 лет

одна запись



раскладываем запись на токены: один признак — один токен

возраст 34	город Казань	сумма покупки 2 400	стаж 3 года
стаж 3 года	возраст 34	сумма покупки 2 400	город Казань

=

те же данные:
порядок токенов
ничего не значит

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

План занятия

- 1 Зоопарк архитектур
- 2 Требование к механизму
- 3 Любые данные — набор токенов
- 4 Вход модели — матрица $L \times d$**
- 5 Внимание: выигрыш и цена

От токена к таблице чисел



физическая природа входа

тот же снимок: 196 строк по 768 чисел $\approx$ 150 тысяч чисел, по два байта — около 300 килобайт

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел

От токена к таблице чисел

- На токен — d чисел,
у всех одно d




физическая природа входа

тот же снимок: 196 строк по 768 чисел $\approx$ 150 тысяч чисел, по два байта — около 300 килобайт

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел

От токена к таблице чисел




- На токен — d чисел, у всех одно d
- L строк по d — матрица X

тот же снимок: 196 строк по 768 чисел $\approx$ 150 тысяч чисел, по два байта — около 300 килобайт

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел

От токена к таблице чисел




- На токен — **d** чисел, у всех одно d
- L строк по d — матрица X
- Оси: L строк, d столбцов

тот же снимок: 196 строк по 768 чисел $\approx$ 150 тысяч чисел, по два байта — около 300 килобайт


- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел

Различается только L



- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Различается только L




- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

План занятия

- 1 Зоопарк архитектур
- 2 Требование к механизму
- 3 Любые данные — набор токенов
- 4 Вход модели — матрица $L \times d$
- 5 **Внимание: выигрыш и цена**

Узкое место энкодера




энкодер — encoder, декодер — decoder; рекуррентная сеть — RNN, recurrent neural network

● Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Матрица X — таблица входа: L строк по d чисел

Эмбединг — embedding — список из d чисел, которым описан один токен

Узкое место энкодера



одно скрытое состояние:

список чисел заданной длины

через это проходит всё

вход и выход бывают любой длины, а мост между ними — постоянного размера

до самой входной фразы декодер не дотягивается: он видит только это состояние

энкодер — encoder, декодер — decoder; рекуррентная сеть — RNN, recurrent neural network

● Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Матрица X — таблица входа: L строк по d чисел

Эмбединг — embedding — список из d чисел, которым описан один токен

Узкое место энкодера

фраза вдвое длиннее — прямоугольник посередине тот же



входная фраза


мы долго искали дом у реки



читает всю фразу строка за строкой

перевод

шаг 1 шаг 2 шаг 3 шаг 4 шаг 5
we looked for this house



выдаёт перевод по одному слову за шаг

одно скрытое состояние:

список чисел заданной длины

через это проходит всё

вход и выход бывают любой длины, а мост между ними — постоянного размера

до самой входной фразы декодер не дотягивается: он видит только это состояние

энкодер — encoder, декодер — decoder; рекуррентная сеть — RNN, recurrent neural network

● Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Матрица X — таблица входа: L строк по d чисел

Эмбединг — embedding — список из d чисел, которым описан один токен

Два способа соединить токены

Рекуррентная сеть



- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Два способа соединить токены

Рекуррентная сеть



каждый токен ждёт предыдущего
чтобы первый дошёл до последнего,
сигнал идёт через все шесть

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Два способа соединить токены

Рекуррентная сеть



каждый токен ждёт предыдущего
чтобы первый дошёл до последнего,
сигнал идёт через все шесть
испорченный телефон

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Два способа соединить токены

Рекуррентная сеть



каждый токен ждёт предыдущего
чтобы первый дошёл до последнего,
сигнал идёт через все шесть
испорченный телефон

Внимание



все токены считаются одновременно
от первого до последнего —
одно прямое соединение
напрямую, за один шаг

считать всё сразу: **нет, только по очереди** считать всё сразу: **да**

путь до дальнего токена: **шесть шагов**

путь до дальнего токена: **один шаг**


- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Вентили отодвигают границу, но не убирают

LSTM и GRU помогают сигналу пройти дальше. Но считать по-прежнему приходится по очереди, а состояние остаётся фиксированного размера.

Где у рекуррентной сети параллелизм

Три кассы — три покупателя сразу



поставили ещё кассу —
стали обслуживать больше сразу

Один чек из многих товаров



сканируются строго по очереди: пока не пробит первый,
второй ждёт — сколько касс ни поставь


вторая касса этому чеку
не помогает никак

покупатель — это пример в батче, а товар в чеке — это токен последовательности

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Свёртка связывает только соседей

каждый слой смотрит только на соседей — охват растёт на один токен в каждую сторону за слой



свёрточная сеть — CNN, convolutional neural network; свёртка с прорежением — dilated convolutions


● Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Матрица X — таблица входа: L строк по d чисел

Эмбединг — embedding — список из d чисел, которым описан один токен

Свёртка связывает только соседей

каждый слой смотрит только на соседей — охват растёт на один токен в каждую сторону за слой



свёрточная сеть — CNN, convolutional neural network; свёртка с прорежением — dilated convolutions


● Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Матрица X — таблица входа: L строк по d чисел

Эмбединг — embedding — список из d чисел, которым описан один токен

Свёртка связывает только соседей

каждый слой смотрит только на соседей — охват растёт на один токен в каждую сторону за слой
один элемент третьего слоя



свёрточная сеть — CNN, convolutional neural network; свёртка с прорежением — dilated convolutions

● Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука

Матрица X — таблица входа: L строк по d чисел

Эмбединг — embedding — список из d чисел, которым описан один токен

Сверка по требованию

Требование	Рекуррентная сеть	Свёрточная сеть	Внимание
Вход любой длины	да	да	да
Прямой доступ к любому токenu	нет	нет	да
Одинаковая цена доступа	нет	нет	да
Нет предположений о данных	нет	нет	да

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Сверка по требованию

Требование	Рекуррентная сеть	Свёрточная сеть	Внимание
Вход любой длины	да	да	да
Прямой доступ к любому токenu	нет	нет	да
Одинаковая цена доступа	нет	нет	да
Нет предположений о данных	нет	нет	да
Чем платит: цена растёт...	как длина	как длина	как площадь

внимание проходит по требованию целиком — и там же видно, чем именно оно за это платит

- Токен — часть входа после нарезки: фрагмент слова, квадрат снимка, окно звука
- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен

Механизм называется ВНИМАНИЕМ

Каждый токен собирает своё описание,
глядя сразу на все остальные и решая,
насколько важен каждый из них.

Что нового у трансформера

2014 — Bahdanau
attention

внимание — надстройка
над рекуррентной сетью:
сеть читает по очереди,
внимание подсказывает,
куда смотреть

2017

рекуррентность убрали
совсем: только внимание
и полносвязные слои
поверх него

Attention Is All
You Need

название статьи,
в которой предложили
архитектуру

Что такое BLEU

Что считает

совпадение с переводом
человека по кускам
в одно, два, три
и четыре слова подряд;
слишком короткий
перевод штрафуются

Чего не видит

смысл и грамматику:
синоним не из эталона
наказан наравне
с ошибкой

Шкала, 0—100

меньше 10 — бесполезно
20 с небольшим — смысл
понятен, ошибок много
30—40 — приличный перевод
человек против человека —
обычно 30—50
28,4 — рабочий уровень,
а не «28% правильно»

Чем измерили победу

Что мерили	Трансформер, 2017
Английский — немецкий, WMT 2014	28,4 BLEU — прежний рекорд превзойдён больше чем на 2 пункта
Английский — французский, WMT 2014	41,8 BLEU — лучший результат на тот момент
Обучение большой версии	3,5 дня на восьми видеокартах



числа разных языковых пар между собой не сравнивают: балл BLEU привязан к паре языков и набору данных

Цена: все пары токенов

строка — токен, столбец — токен, клетка — одно сравнение

восемь токенов — вдвое длиннее

четыре токена



столько было

вход вырос вдвое — таблица сравнений вчетверо

196 токенов — это 38 416 пар; видео 8 кадров по 14×14 — это 1568 токенов и почти 2,5 миллиона пар



- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен
- Внимание — механизм, где каждый токен смотрит сразу на все

Цена: все пары токенов

строка — токен, столбец — токен, клетка — одно сравнение

восемь токенов — вдвое длиннее

четыре токена



столько было

вход вырос вдвое — таблица сравнений вчетверо

- L токенов — это L^2 сравнений

196 токенов — это 38 416 пар; видео 8 кадров по 14×14 — это 1568 токенов и почти 2,5 миллиона пар



- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен
- Внимание — механизм, где каждый токен смотрит сразу на все

Цена: все пары токенов

строка — токен, столбец — токен, клетка — одно сравнение

восемь токенов — вдвое длиннее

четыре токена



столько было

вход вырос вдвое — таблица сравнений вчетверо

- L токенов — это L^2 сравнений
- Видео — самая дорогая модальность

196 токенов — это 38 416 пар; видео 8 кадров по 14×14 — это 1568 токенов и почти 2,5 миллиона пар



- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен
- Внимание — механизм, где каждый токен смотрит сразу на все

Цена: все пары токенов

строка — токен, столбец — токен, клетка — одно сравнение

восемь токенов — вдвое длиннее

четыре токена



столько было

вход вырос вдвое — таблица сравнений вчетверо

- L токенов — это L^2 сравнений
- Видео — самая дорогая модальность
- Упираемся в память, не во время

196 токенов — это 38 416 пар; видео 8 кадров по 14×14 — это 1568 токенов и почти 2,5 миллиона пар

- Матрица X — таблица входа: L строк по d чисел
- Эмбединг — embedding — список из d чисел, которым описан один токен
- Внимание — механизм, где каждый токен смотрит сразу на все

Когда внимание дешевле

Слой внимания

L^2 сравнений,
в каждом — работа
с d числами токена

Рекуррентный слой

L шагов, на каждом
умножение состояния
на матрицу $d \times d$:
порядка d^2 чисел

Пока $L < d$

слой внимания
обходится дешевле;
перевод — это
десятки токенов
при $d = 512$

квадратичная плата кусается там, где L дорастает до d : страница текста, снимок высокого разрешения, минуты видео

Что считаем токеном

Вид данных	Что считаем токеном	Модуль
Текст	фрагмент слова	1
Изображение	квадратный участок картинки	2
Звук	короткое окно записи	3
Видео	участок кадра за несколько кадров	4
Временные ряды	отрезок ряда	4
Таблицы	отдельный признак записи	4

Что ломается при нарезке

в картинке у токена четыре соседа, в цепочке — два
соседство по вертикали при разворачивании пропадает, и модель о нём сама не догадается
в картинке

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

токены 2 и 6 —
соседи по вертикали,
они соприкасаются

- Матрица X — таблица входа: L строк по d чисел
Эмбединг — embedding — список из d чисел, которым описан один токен
Внимание — механизм, где каждый токен смотрит сразу на все

Что ломается при нарезке

в картинке у токена четыре соседа, в цепочке — два
соседство по вертикали при разворачивании пропадает, и модель о нём сама не догадается
в картинке

1	2	3	4
5	6	7	8
9	10	11	12
13	14	15	16

токены 2 и 6 —
соседи по вертикали,
они соприкасаются



в цепочке

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
---	---	---	---	---	---	---	---	---	----	----	----	----	----	----	----

между ними три чужих токена

- Матрица X — таблица входа: L строк по d чисел
Эмбединг — embedding — список из d чисел, которым описан один токен
Внимание — механизм, где каждый токен смотрит сразу на все

Что мы установили

- Каждая прежняя сеть знала про свои данные заранее
- Любые данные режутся на токены
- Вход модели — матрица X : L строк по d чисел
- Очередь и длинный путь — у рекуррентной сети
- Внимание: прямой доступ по одинаковой цене

Универсален не потому, что умнее


Трансформер ничего не предполагает о данных заранее. Остальное в курсе — следствия этой сделки, включая её цену.

Итоги занятия

- Каждая прежняя сеть закладывала догадку о своих данных
- Любые данные — набор токенов; различается только L
- Вход модели везде один: матрица X размера $L \times d$
- Рекуррентная сеть считает по очереди, путь идёт по цепочке
- Прямой доступ платит по числу пар: цена — как площадь
- Чего механизм не знает заранее, тому его придётся учить

Что читать дальше

- Vaswani et al., Attention Is All You Need, 2017:
arxiv.org/abs/1706.03762
- Dosovitskiy et al., An Image Is Worth 16x16 Words, 2020:
arxiv.org/abs/2010.11929
- Radford et al., Whisper, 2022: arxiv.org/abs/2212.04356
- Tay et al., Efficient Transformers: A Survey, 2020:
arxiv.org/abs/2009.06732



Ваши вопросы

Единый принцип и зачем нужны трансформеры

Дисциплина «Мультимодальная обработка данных»

Александр Чурсин
Руководитель группы
разработки в ГК «Норильский
никель»

